



Прогнозування вартості медичного страхування

Аналіз факторів впливу та побудова моделей Machine Learning

Автор: Кузевич Іван

Набір даних та обробка

Джерело: стандартний набір даних з 1338 записів. Ознаки: **age**, **sex**, **bmi**, **children**, **smoker**, **region**, **charges**.

Очищення даних

Перевірка на дублі, некоректні значення і типи змінних — жодних пропущених значень не виявлено.


Пропуски

0 пропусків у наборі — готово до аналізу без імпутації.

Перевірка на пропуски:

```
age      0
sex      0
bmi      0
children 0
smoker   0
region   0
charges  0
dtype: int64
```

Експлораторний аналіз (EDA)




Ключова статистики:

- Середній вік: **39 років**
- Середня вартість поліса (charges): **\$13,270**
- Середній ІМТ (BMI): **~30** — підвищений ризик для частини вибірки

За гістограмою видно позитивно-правозміщений розподіл цільової змінної з кількома значними аутлаєрами — важливо для вибору метрик та обробки помилок.


Взаємозв'язки та кореляція



Аналіз матриці кореляції виявив такі закономірності:

- **Age** має помірно сильний позитивний зв'язок з charges.
- **BMI** корелює з витратами, особливо в підгрупах курців.
- **Smoker** — найсильніший категоріальний драйвер вартості (значне збільшення charges для курців).

Висновок: виявили, що фактори працюють у зв'язці. Наприклад, поєднання "**курець + висока вага (BMI)**" дає набагато більший приріст ціни, ніж ці фактори окремо. Також вартість страховки для курців зростає з віком значно швидше, ніж для тих, хто не курить.



Побудова та навчання моделей

01

Підготовка вибірки

Розподіл на Train/Test 80/20,
стратифікація по Smoker для
збалансованості.

02

Моделі

1) Linear Regression — базова інтерпретована модель. 2) Random Forest — нелінійний ансамблевий підхід для складних впливів.



03

Гіперпараметри

Random Forest: number of estimators, max depth, min samples leaf;
використано крос- валідацію для вибору.

Оцінка якості та результати

Порівняння метрик показує кращу продуктивність Random Forest ($R^2 = \mathbf{0.86}$) проти лінійної моделі ($R^2 = \mathbf{0.78}$).



Feature Importance: Smoker $\approx 60\%$ від загального впливу; Age та BMI — наступні за значущістю; інші ознаки мають менший вплив.

Висновки та практичне застосування



Наступні кроки: А/В тестування моделі в продакшн, моніторинг дрейфу даних та періодичне перенавчання.

Резюме

Random Forest забезпечує кращу точність для прогнозування вартості полісів за рахунок захоплення нелінійних взаємодій.

Практичне застосування

Інтеграція в тарифікаційну систему: автоматичний попередній розрахунок ціни, підказки андеррайтеру, динамічні корекції ризику.

Шляхи вдосконалення

Додати зовнішні дані (медична історія, поведінкові фактори), тестувати градієнтні бустинги, налаштувати калібрування прогнозів і СІ для ризик-менеджменту.

Дякую за увагу!!!

